

Graph Neural Networks (Scarselli, 2009)

Aleksy Barcz

19 maja 2013

Cechy GNN

- ▶ Klasyfikator dowolnych grafów (niepozycyjne, cykle)
- ▶ Klasyfikacja węzłów i klasyfikacja grafów
- ▶ Oparty na FNN
- ▶ Proste rozwiązanie problemu cykli

Cel implementacji

- ▶ Sprawdzenie działania GNN i identyfikacja kluczowych parametrów
- ▶ Utworzenie wygodnego i uniwersalnego środowiska
- ▶ Wybrana platforma implementacji : Octave

Format reprezentacji grafu

- ▶ *nodes.csv* (etykiety węzłów):
każdy wiersz = l_n ; ($|l_n| \geq 1$)
- ▶ *edges.csv* (etykiety krawędzi $x_u \Rightarrow x_n$):
każdy wiersz = id_u, id_n, l_{un} ;
(id_n : indeks węzła n w pliku *nodes.csv*)
(l_{un} : etykieta krawędzi, $|l_{un}| \geq 0$)
- ▶ *output.csv* (oczekiwane wyjścia węzłów lub grafu):
każdy wiersz = o_n ; ($|o_n| \geq 1$)
lub
pojedynczy wiersz = klasa grafu

Koncepcja GNN

- ▶ Pojedyncza sieć dla wszystkich grafów należących do problemu
- ▶ Dla każdego wężła automatycznie budowana reprezentacja:
 $x_n = f(\dots)$
- ▶ Klasyfikacja wężła: $o_n = g(x_n)$
- ▶ Dla zagadnienia klasyfikacji grafów, wybieramy wierzchołek reprezentujący graf

Składowe GNN

- ▶ Dwie jednostki obliczeniowe : f_w i g_w
- ▶ Wszystkie instancje f_w współdzielą wagi
- ▶ Wszystkie instancje g_w współdzielą wagi
- ▶ Instancje f_w połączone w metasieć odwzorowującą połączenia w grafie

Składowe GNN - grafy niepozycyjne

- ▶ Stan węzła:

$$x_n = f_w(\dots) = \sum_{u: u \Rightarrow n} h_w(l_n, l_{nu}, x_u)$$

- ▶ Wyjście węzła:

$$o_n = g_w(x_n)$$

- ▶ h_w : FNN

(wejścia, warstwa ukryta *tanh*, warstwa wyjściowa *tanh*)

- ▶ g_w : FNN

(wejścia, warstwa ukryta *tanh*, warstwa wyjściowa dowolna)

Postać globalna

- ▶ $X = x_1, x_2, \dots, x_m$: stan - reprezentacja wszystkich węzłów grafu, zbudowana przez F_w
- ▶ $F_w(X)$: globalna funkcja przejścia, $F_w(X) = X$
- ▶ F_w jest kontrakcją, a wyznaczany X - jej punktem stałym
- ▶ $G_w(X)$: globalna funkcja wyjścia


Własności F_w (tw. Banacha)

- ▶ kontrakcja : $\|F_w(X_1) - F_w(X_2)\| \leq \|X_1 - X_2\|$
- ▶ posiada dokładnie jeden punkt stały
- ▶ zbieżność F_w niezależna od punktu początkowego
- ▶ zbieżność wykładnicza - potrzebna bardzo mała ilość powtórzeń (ok. 5 do 15)
- ▶ jak zapewnić by F_w była kontrakcją?

Schemat działania


1. Losowa inicjalizacja stanu X
2. do osiągnięcia kryterium stopu:
 - ▶ FORWARD : obliczenie $X = F_w(X)$ aż do osiągnięcia punktu stałego
 - ▶ BACKWARD : obliczenie $G_w(X)$ i propagacja wsteczna błędu
 - ▶ aktualizacja wag f_w i g_w

Forward - budowanie stanu



- ▶ BPTT
- ▶ *minStateDiff*

Backward - propagacja wsteczna błędu



- ▶ Almeida-Pineda *minErrorDiff*
- ▶ Kara za brak kontrakcji *contracionConstant*
- ▶ RPROP *deltaMax*

Zbiór danych

- ▶ Wykrywanie podgrafu
- ▶ Podobny do zbioru Scarselli
- ▶ 6 węzłów, 3 węzły podgrafu, $p_{edge} = 0.8$ (zamiast 0.2)
- ▶ Etykiety węzłów 0..10
- ▶ Szum Gaussowski średnia=0 std=0.25
- ▶ 20 grafów

Parametry modelu - stałe

FNN - zgodne z zaleceniami:

- ▶ liczba neuronów ukrytych h_w : 5
- ▶ liczba neuronów ukrytych g_w : 5
- ▶ rozmiar stanu x_n : 5

RPROP - zgodne z zaleceniami:

- ▶ *initialDelta* : 0.1
- ▶ *minDelta* : 10e-6
- ▶ *maxDelta* : 1.0 (zalecana wartość alternatywna)
- ▶ *factor+* : 1.2
- ▶ *factor-* : 0.5

Parametry modelu - modyfikowane

Zależne od problemu:

- ▶ *minStateDiff* : $10e-8 \dots 10e-5$
- ▶ *minErrorDiff* : jw.
- ▶ *contractionConstant* : $0.5 \dots 1.2$










Eksperymenty







Legenda:







- ▶ *nForward* : ilość kroków procedury budowania stanu (przerywana po przekroczeniu 200)
- ▶ *nBackward* : ilość kroków akumulacji błędu (Almeida-Pineda, przerywane po przekroczeniu 200)
- ▶ *penalty* : czy na którąkolwiek z wag została nałożona kara kontrakcji?
- ▶ *de/dw influence* : procent korekt wag zgodnych znakiem z gradientem błędu
- ▶ *dp/dw influence* : procent korekt wag zgodnych znakiem z pochodną kary kontrakcji







Eksperyment 1 : wpływ początkowych wartości wag







- ▶ 10 grafów
- ▶ 9 sieci GNN o losowych wagach
- ▶ $\text{contractionConstant} = 0.9$
- ▶ $\text{minStateDiff} = 10\text{e-}08$
- ▶ $\text{minErrorDiff} = \text{minStateDiff}$



































Eksperyment 2 : wpływ parametrów GNN







- ▶ 20 grafów
- ▶ jeden zestaw początkowych wartości wag
- ▶ *contractionConstant* = 1.2, 0.9, 0.6
- ▶ *minStateDiff* = 10e-08, 10e-07
- ▶ *minErrorDiff* = *minStateDiff*
- ▶ wybrana sieć nr 7 z poprzedniego eksperymentu



























Klasyfikacja węzłów - wyniki

	accuracy	precision	recall
TR - średnia	79%	83%	79%
TR - std	8%	4%	14%
TST - średnia	75%	76%	81%
TST - std	8%	10%	14%







Tabela: 5-krotna walidacja krzyżowa, najlepsza sieć z 10ciu, 200 iteracji

Klasyfikacja węzłów - 100 grafów

	accuracy	precision	recall
GNN - TR	90%	88%	95%
GNN - TST	87%	84%	95%
FNN - TR	96%	94%	100%
FNN - TST	97%	95%	100%

Tabela: Klasyfikacja węzłów 100 iteracji

- ▶ zbiór uczący : 80 grafów
- ▶ zbiór testowy : 20 grafów
- ▶ wykorzystana GNN nr 5 z eksperymentu 1 (najlepsza)
- ▶ wykorzystana do porównania FNN z 5 neuronami ukrytymi



Wnioski

- ▶ Najlepszy efekt przy zachowaniu kontrakcji
- ▶ Brak zbieżności kontrakcji – brak poprawy
- ▶ Balansowanie na granicy zbieżności / ograniczona ilość kroków obliczenia stanu i błędu dopuszczalne
- ▶ Należy unikać nakładania niepotrzebnie kary kontrakcji
- ▶ Konieczna duża dokładność w sprawdzaniu punktu stałego
- ▶ Duża wrażliwość modelu na parametry
- ▶ Można dobrać zestaw parametrów (i początkowych wag) na podzbiorze danych